Codebook adnotacji semantycznej v0.1.2: tweety Trumpa

Nov 1, 2026 · @Paulina

1. Cel i zakres

Codebook opisuje, jak ręcznie oznaczamy tweety Donalda Trumpa, żeby powstał gold standard: zbiór postów z pewnymi etykietami. Służy on do walidacji instrumentu, czyli sprawdzenia, czy słownik cłów wybiera właściwe tweety i czy klasyfikator poprawnie rozpoznaje kierunek sygnału. Bez tego nie wiadomo, czy tweety-zdarzenia w danych scalonych naprawdę dotyczą cłów, ani co sygnalizują rynkowi.

- **Materiał:** oryginalne posty Donalda Trumpa z Twittera, 2018–2019, bez retweetów i bez postów będących samym linkiem.
- **Poza zakresem tej wersji:** nagłówki medialne (FNSPID), rama narracyjna i powiązanie posta z konkretnym zdarzeniem GTA/FR. Media wchodzą do modelu tylko jako liczności.
- **Czego nie oznaczamy:** sentymentu. Trump niemal zawsze mówi o cłach pozytywnie, więc jego ton nie niesie informacji o reakcji rynku. Oznaczamy, czy post dotyczy cłów, i kierunek sygnału.
- **Do czego służą etykiety:** walidacja słownika cłów, ocena klasyfikatora na części testowej oraz zmienna kierunek w analizie (event study, Local Projections, PCMCI+).

2. Jednostka i zasady ogólne

Jednostką jest jeden post i oznaczamy go wyłącznie na podstawie jego treści.

1. **Adnotacja ślepa.** Nie sprawdzamy, jak zareagował rynek ani co stało się po publikacji. Wiedza o wyniku psuje etykiety.
2. **Liczy się główny przekaz.** Gdy post ma kilka wątków, wybieramy ten, któremu poświęcono najwięcej słów, a przy remisie ten, który występuje pierwszy.
3. **Oznaczamy to, co napisano,** a nie to, co autor mógł mieć na myśli. Nie korzystamy z kontekstu z innych źródeł (wiadomości, kalendarza ceł).
4. **Wątpliwość = NEUTRALNE / inne**, z krótką uwagą w kolumnie `uwagi`. Nie zgadujemy.
5. **Każdy oznacza samodzielnie** do momentu rozstrzygania. Nie konsultujemy pojedynczych przypadków w trakcie, tylko zapisujemy je w uwagach i omawiamy po pilotażu.

3. Etykieta `cla` — czy dotyczy ceł, sankcji lub handlu

Wartości: `tak` / `nie`.

`tak`, gdy główny przekaz dotyczy ceł, sankcji, ograniczeń handlowych, umów lub negocjacji handlowych, deficytu handlowego jako skutku polityki handlowej albo bezpośrednio ich skutków dla firm i rynków.

`nie`, gdy słowo kluczowe (china, import, trade, steel) pojawia się w innym kontekście: wybory, Rosja, imigracja, wojsko, wywiad, ataki na media, komentarz do wydarzeń sportowych.

Przykład (parafraza)	Etykieta	Dlaczego
Wprowadzamy 25% cła na chińską stal	tak	konkretny środek handlowy
Chiny oszukują nas od lat, deficyt jest ogromny	tak	argument o handlu, bez nowego środka
Rozmawiałem z prezydentem Xi o Korei Północnej	nie	rozmowa o bezpieczeństwie, nie o handlu
Fake news media znowu kłamie o gospodarce	nie	atak na media, brak wątku handlowego

Reguła brzegowa: sankcje wobec Rosji, Iranu lub Wenezueli oznaczamy `tak`, bo są ograniczeniem handlowo-finansowym. Samą zapowiedź rozmów "o handlu" bez żadnych szczegółów też `tak`.

4. Etykieta `kierunek` — kierunek sygnału

Oznaczamy tylko posty z `cla = tak`. Pytanie: czy post zapowiada zaostrzenie, czy złagodzenie sytuacji handlowej?

Wartość	Definicja	Przykład (parafraza)
`ESKALACJA`	nowe cło, groźba, odwet, podwyżka stawki, zerwanie rozmów	Jeśli nie przestaną, nakładamy część drugą od 1 września
`DEESKALACJA`	porozumienie, odroczenie, obniżka, postęp rozmów, spotkanie	Rozmowy z Chinami idą bardzo dobrze, odkładamy podwyżki
`NEUTRALNE`	opis stanu rzeczy, ocena przeszłości, brak sygnału zmiany	Deficyt handlowy z Chinami wyniósł w zeszłym roku X

Reguły:

- Liczy się **kierunek zmiany względem stanu sprzed posta**, nie ton. "Cła są wspaniałe i będą wyższe" to `ESKALACJA`.
- Pochwała istniejących ceł bez zapowiedzi zmiany to `NEUTRALNE`.
- Gdy w jednym poście występują oba kierunki, stosujemy regułę głównego przekazu z sekcji 2. Gdy nadal nie wiadomo, `NEUTRALNE` z uwagą.

5. Etykieta `emocja` (opcjonalna)

Wartości: `gniew`, `duma`, `optymizm`, `grozba`, `inne`, `brak`. Jedna dominująca emocja posta. Wypełniamy ją po oznaczeniu `cla` i `kierunek` i tylko wtedy, gdy zespół po pilotażu uzna, że jest potrzebna. Nie wchodzi do liczenia zgodności (kappy).

6. Reguły brzegowe

Sytuacja	Decyzja
Sarkazm lub ironia ("wspaniałe cła Chin, dziękuję")	oznaczamy znaczenie zamierzone, nie dosłowne; przy braku pewności `NEUTRALNE` + uwaga
Groźba warunkowa ("jeśli Chiny nie..., nakładamy")	`ESKALACJA`
Warunkowa obietnica ("jeśli podpiszą, zniesiemy")	`DEESKALACJA`
Pochwała istniejących ceł bez zapowiedzi zmiany	`cla = tak`, `NEUTRALNE`
Kilka tematów w jednym poście	reguła głównego przekazu (sekcja 2)
Retweet lub cytat cudzego tekstu	poza próbką; jeśli trafił, oznaczamy jak zwykły tekst i dopisujemy uwagę
Tekst z wtrąceniem o innym kraju (Meksyk, UE)	`cla = tak`, jeśli dotyczy handlu; kraj trafia do uwag
Post o wynikach giełdy lub gospodarki bez ceł	`cla = nie`

Posty będące samym linkiem nie trafiają do próbki.

Jeśli pojawi się przypadek, którego tu nie ma, zapisujemy go w uwagach i dodajemy do tabeli po rozstrzyganiu (nowa wersja codebooka, sekcja 10).

7. Procedura oznaczania

1. **Próbka (notebook 03, etap A).** 400 postów, losowanie warstwowe: miesiąc × trafienie słownika, połowa próbki to posty uznane przez słownik za cła. Każdy post ma wagę (odwrotność prawdopodobieństwa wylosowania), stałe ziarno 2026. Plan zapisuje się w `klucz_probki.csv` i po rozesłaniu arkuszy nie jest losowany ponownie.
2. **Pilotaż.** 50 postów oznaczają wszystkie cztery osoby (`1_pilotaz_<inicjały>.xlsx`). Notebook liczy alfę Krippendorffa i pokazuje, gdzie mylimy kierunek. Po spotkaniu poprawiamy codebook i wpisujemy zmianę do historii. Jeśli definicje zmieniły się istotnie, posty z pilotażu wyłączamy z gold (`include_pilot=False`).
3. **Część główna** (`2_glowna_<inicjały>.xlsx`). Nakładka: 120 postów, każdy oznacza para osób, sześć par po 20 postów. Reszta (230 postów) po równo, jedna osoba na post. Razem ok. 168 postów na osobę.
4. **Zgodność.** Kappa Cohena dla każdej pary i alfa Krippendorffa na nakładce, osobno dla `cla` i `kierunek | cla=tak`. Cel: **>= 0,70**. Poniżej celu poprawiamy definicje i oznaczamy nową nakładkę.
5. **Rozstrzyganie.** Notebook tworzy `rozstrzyganie.xlsx` ze spornymi postami. Tam, gdzie jest zgoda albo większość, `FINAL_cla` i `FINAL_kierunek` są już wypełnione. Na spotkaniu uzupełniamy puste pola i obowiązkowo `uzasadnienie`. Nowe spory są dopisywane do pliku, a wcześniejsze wpisy zostają.
6. **Gold i podział.** Powstaje `gold_standard.xlsx` (i `.csv` dla skryptów), podzielony warstwowo po (cla, kierunek) na część dev (40%: dobór promptu lub modelu) i test (60%: tylko ocena końcowa, bez podglądania).
7. **Walidacja instrumentu i ocena klasyfikatora:** sekcja 9.

"100% pewności" jest nierealne. Realnym celem są opisana zgodność między oznaczającymi i jawne rozstrzyganie przypadków spornych.

8. Pliki do wypełniania (Excel)

Notebook `03_annotation.ipynb` tworzy wszystkie pliki w folderze `adnotacja/`. Inicjały: BB (Borkowski), IK (Kowalczyk), MG (Gadomski), PK (Korus).

Plik	Dla kogo	Zawartość
`1_pilotaz_<inicjały>.xlsx`	każda osoba	50 postów pilotażu

Plik	Dla kogo	Zawartość
`2_glowna_<inicjały>.xlsx`	każda osoba	posty z nakładki i własne (ok. 118)
`INSTRUKCJA.md`	wszyscy	skrót codebooka (ta sama treść jest w karcie Instrukcja każdego arkusza)
`klucz_probki.csv`	tylko osoba prowadząca	powiązanie z `post_id`, wagi, warstwy; nie rozsyłamy (adnotacja ślepa)
`rozstrzyganie.xlsx`	cały zespół na spotkaniu	posty sporne, `FINAL_cla`, `FINAL_kierunek`, `uzasadnienie`
`gold_standard.xlsx` (+ `.csv`)	wynik	etykiety ostateczne, źródło etykiety, podział dev/test

Kolumny arkusza: `item_id`, `etap`, `data_utc`, `tekst` (szare, zablokowane) oraz żółte do wypełnienia: `cla`, `kierunek`, `emocja`, `uwagi`.

Zasady wypełniania:

- Wartości wybieramy z listy rozwijanej (strzałka przy zaznaczonej komórce). Excel nie przyjmie wartości spoza listy.
- Przy `cla = nie` kierunek zostaje pusty. Pomarańczowe pole oznacza, że przy `cla = tak` brakuje kierunku.
- Nie sortujemy i nie usuwamy wierszy. Szare kolumny są zablokowane (ochrona arkusza bez hasła).
- Zapisujemy zwykłym Ctrl+S jako .xlsx, bez zmiany nazwy. Plik wraca do `adnotacja/`.
- Notebook nigdy nie nadpisuje arkusza, w którym są już wpisy.

9. Walidacja instrumentu

Instrument to dwie rzeczy: codebook z oznaczającymi oraz słownik cłów, który w danych scalonych wybiera tweety-zdarzenia. Notebook 03 (etapy C, E, F) sprawdza je tak:

Co sprawdzamy	Miara	Próg lub punkt odniesienia
rzetelność oznaczania	kappa Cohena (pary) i alfa Krippendorffa na nakładce	>= 0,70 dla `cla` i `kierunek | cla=tak`

Co sprawdzamy	Miara	Próg lub punkt odniesienia
trafność słownika cłów	precyzja i czułość względem gold, ważone wagami próbkowania (szacunek dla całego korpusu)	lista pomyłek służy do poprawy słownika
klasyfikator (LLM lub zero-shot)	accuracy, macro-F1 i macierz pomyłek na części test	musi wyraźnie pokonać klasę najczęstszą i reguły słownikowe

Połączenie z danymi scalonymi (etap G):

- post → zdarzenie: `event_id = tw_<post_id>` w `events.csv`, `event_table.csv` i `market_long.csv`;
- post → epizod: epizod, który zaczął się najpóźniej przed postem (reguła 6 h);
- post → dzień: `eff_day`, czyli klucz paneli `daily` i `trading`; dzienne liczniki per etykieta dodaje `add_label_counts`.

Posty z gold, których słownik nie złapał, nie są zdarzeniami w danych scalonych. Służą walidacji. Do analizy rynku etykiety wchodzą w całości dopiero po oznaczeniu całego korpusu klasyfikatorem i przebudowaniu scalenia (`build_merged(..., relevant_col=...)`).

10. Historia zmian

Wersja	Data	Zmiana	Autor
0.1	2026-11-01	Pierwszy szkic przed pilotażem: etykiety `cla`, `kierunek`, `rama`, `emocja`, `id_zdarzenia`, reguły brzegowe, procedura	zespół
0.1.1	2026-11-01	Zakres zawężony do tweetów Trumpa (bez nagłówków FNSPID); procedura oparta na plikach z notebooka 03; sekcje o plikach i walidacji instrumentu	zespół
0.1.2	2026-11-01	Usunięte etykiety `rama` i `id_zdarzenia` (wraz z listą kandydatów zdarzeń); arkusze w Excelu (.xlsx) z listami rozwijanymi; numeracja sekcji przesunięta	zespół
0.2		po pilotażu (50 postów, 4 osoby)	