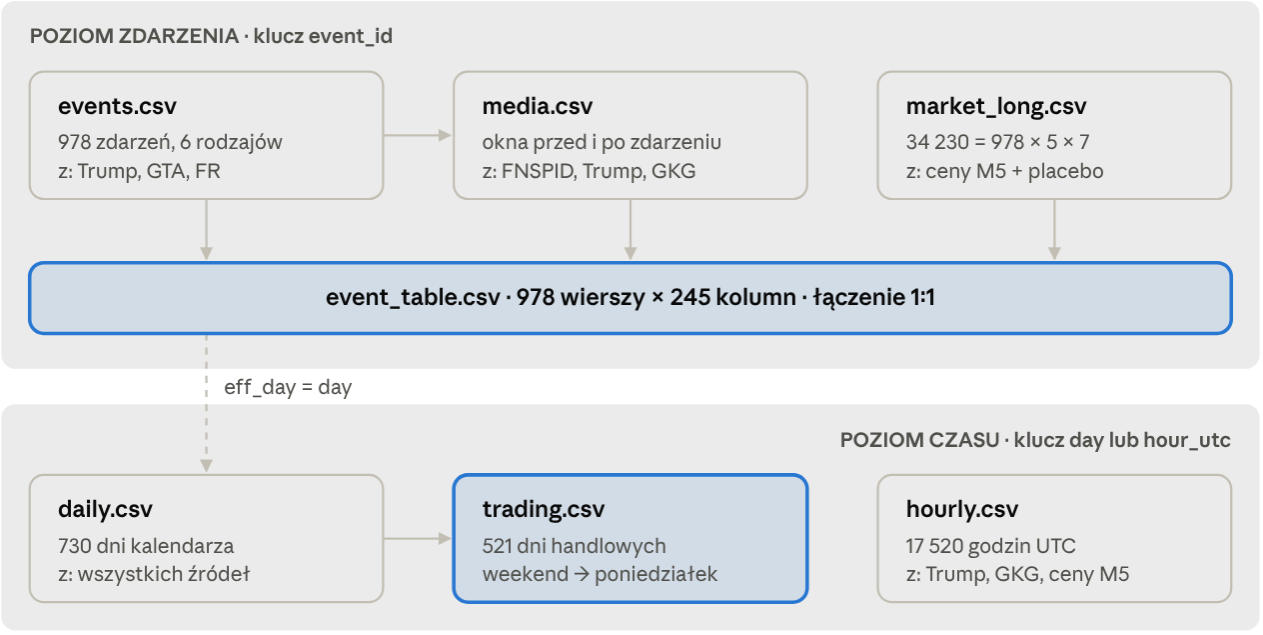
Pliki scalone (clean_out/merged): co zawierają i jak ich użyć w modelu

Nov 1, 2026 · @Paulina

Mapa plików

Siedem plików tworzy dwa poziomy. Pliki zdarzeń łączą się po `event_id` i opisują reakcję na konkretny tweet lub decyzję w minutach i dniach. Panele czasu to ciągłe szeregi dzienne i godzinowe, a z poziomem zdarzeń łączą się przez `eff_day = day`. Wyróżnione są dwa pliki, od których zwykle zaczyna się model: `event_table.csv` i `trading.csv`.

Dwa poziomy plików: zdarzenia (event_id) i czas (dzień, godzina)



pliki w clean_out/merged · 2 poziomy, 7 plików

Plik	Jeden wiersz to	Klucz	Wiersze u Was	Do czego w modelu
`events.csv`	zdarzenie (tweet, epizod, decyzja GTA/FR)	`event_id`	978	wybór szoku `t`
`media.csv`	zdarzenie: liczba artykułów i tweetów przed i po nim	`event_id`	978	Trump → media

Plik	Jeden wiersz to	Klucz	Wiersze u Was	Do czego w modelu
`market_long.csv`	zdarzenie × instrument × horyzont	`event_id` + `instrument` + `horizon`	34 230	Trump → rynek (event study)
`event_table.csv`	zdarzenie ze wszystkim naraz	`event_id`	978 (245 kolumn)	regresje na zdarzeniach
`daily.csv`	dzień kalendarza	`day` (= `eff_day`)	730	wykresy, profile dni
`trading.csv`	dzień handlowy	`day`	521	Local Projections, PCMCI+
`hourly.csv`	godzina UTC	`hour_utc`	17 520	test kolejności w godzinach

Źródła danych

Dane pochodzą z siedmiu baz. Notebook `01_cleaning.ipynb` pobiera i czyści każdą osobno do folderu `clean_out/`, a dopiero `02_merging.ipynb` łączy je w 7 plików scalonych. Każda kolumna plików scalonych pochodzi z jednej z tych baz albo jest z nich wyliczona.

Baza	Co zawiera	Skąd pobrana	Plik surowy	Plik po czyszczeniu	Dokładność czasu
Twitter (archiwum tweetów Trumpa)	posty i retweety, polubienia, liczba retweetów	Kaggle: `codebreaker619/donald-trump-tweets-dataset`	`data/trump_tweets.csv`	`clean_out/trump/trump_clean.csv`	sekunda, UTC
FNSPID (Financial News and Stock Price Integration Dataset)	nagłówki wiadomości finansowych z tickerem i wydawcą	plik zespołu, wstępnie zawężony do tematu ceł	`data/fnspid_tariffs_clean.csv`	`clean_out/fnspid/fnspid_clean.csv`	dzień
GDELT GKG 2.1	metadane artykułów z całego świata w paczkach 15-minutowych: adres, źródło, motywy	data.gdeltproject.org, próbka paczek wokół dat kluczowych	`gdelt_data/gkg/*.gkg.csv.zip`	`clean_out/gkg/gkg_clean.csv`	15 min (czas przetworzenia paczki, nie publikacji)
Global Trade Alert (GTA)	interwencje handlowe wdrażane przez USA i Chiny: tytuł, data ogłoszenia, data wejścia w życie, kraje dotknięte, liczba produktów	API GTA (z kluczem)	`events_out/gta_interventions.csv`	`clean_out/gta/gta_clean.csv`	dzień
Federal Register	dokumenty rządu USA o cłach (zapytania: Section 301, Section 232, IEEPA, reciprocal)	API federalregister.gov	`events_out/fr_cache_v2.csv`	`clean_out/federal_register/fr_clean.csv`	dzień

Baza	Co zawiera	Skąd pobrana	Plik surowy	Plik po czyszczeniu	Dokładność czasu
Archiwum notowań (`data.taz`)	świece 5-minutowe bid i ask: S&P 500, Nasdaq, Hang Seng, EURUSD, TLT	archiwum zespołu (nazwy w konwencji Dukascopy, np. `usa500idxusd`)	`data/market_data/`	`clean_out/market/<INSTRUMENT>_mid.csv`	5 min, UTC
FRED (VIX)	dzienne zamknięcie indeksu VIX (seria VIXCLS)	fred.stlouisfed.org	—	`data/vix_daily.csv`	dzień

VIX nie wchodzi do plików scalonych, dokłada się go w modelu po dacie (sekcja 7). Daty kluczowe na slajdach (11 dat) są wpisane ręcznie w konfiguracji (`Config.key_events`) i nie są kolumną żadnego pliku.

Krok po kroku: od surowych danych do 7 plików

Pliki powstają w dwóch etapach: najpierw każda baza jest czyszczona osobno, potem wszystkie są łączone na wspólnej osi czasu UTC.

Etap 1: czyszczenie (`01_cleaning.ipynb` , funkcja `run_cleaning` , każda baza osobno)

1. **Twitter.** Ujednolicenie kolumn: czas → `time_utc` (UTC), identyfikator → `post_id` , polubienia → `favs` , retweety → `rts` . Usunięcie duplikatów, oznaczenie retweetów (`is_retweet`). Słownik słów: `relevant_strict` (słowa o cłach i handlu), `china_trade` (Chiny w kontekście handlu), `relevant` = jedno albo drugie. Do tego `thread` (kraj lub produkt ze słownika) i `session` (sesja giełdy w Nowym Jorku).
2. **FNSPID.** Czas `t_utc` (północ oznacza samą datę, wtedy `has_time = False`). `is_topic` : słownik słów w tytule. `story_key` i `is_first_in_story` : ta sama wiadomość przypisana kilku tickerom liczy się raz. `is_sector_note` : notki zbiorcze typu „Shares of several…”. `thread` : wątek ze słownika.
3. **GDELT GKG.** Z każdej paczki 15-minutowej zostają artykuły o cłach: słowa w adresie URL albo motywy z pola V2Themes (np. `ECON_TRADE_DISPUTE` , `SANCTIONS`). `time_utc` to pole `DATE` , czyli czas przetworzenia paczki.
4. **GTA.** Okres 2018–2019, usunięcie duplikatów (`intervention_id` , `actor`), flagi anomalii (np. wejście w życie przed ogłoszeniem).
5. **Federal Register.** Okres 2018–2019, jeden wiersz na dokument (zapytania scalone w `queries`). `core` : ścisły słownik słów bez dokumentów-szumu (np. antydumping, przeglądy administracyjne). `event_date` = data podpisu, a gdy jej brak, publikacji.
6. **Rynek.** Tylko 5 instrumentów. Czyszczenie świec bid i ask, potem średnia z obu: `mid_open` , `mid_close` , do tego `spread_close` i `flag_crossed` (ask niższy niż bid).

Etap 2: scalanie (`02_merging.ipynb` , funkcja `build_merged`)

7. **Wczytanie** czystych plików: typy, strefa UTC, świece z ask < bid wyzerowane, lista pobranych paczek GKG (z nazw plików).

8. **Zdarzenia → `events.csv`.** Posty o cłach (`relevant`, bez retweetów, 2018–2019); epizody (nowy po co najmniej 6 h przerwy); GTA zgrupowane w dzień × kraj, osobno ogłoszenia i wejścia w życie (1 stycznia pominięty, bo w GTA to zwykle data zastępcza); dokumenty FR typu `core` z datą podpisu lub publikacji oraz z datą wejścia w życie.
9. **FNSPID dziennie.** Liczba historii na dzień: `fn_n`, `fn_all_n`, `fn_sector_n`, wątki.
10. **Media wokół zdarzeń → `media.csv`.** Okna przed i po każdym zdarzeniu: FNSPID w dniach, kolejne tweety i GKG w godzinach.
11. **Rynek wokół zdarzeń → `market_long.csv`.** Zwroty z `mid_open` po zdarzeniu i przed nim, 20 losowych chwil kontrolnych (placebo), nadwyżki.
12. **`event_table.csv`.** `events` + `media` + `market_long` rozpisany szeroko, łączone po `event_id` w relacji 1:1.
13. **Panele.** `daily.csv` (dzień w kluczu `eff_day`), `trading.csv` (dni handlowe, weekend doliczony do poniedziałku), `hourly.csv` (godziny UTC). Rynek w panelach liczony z `mid_close`.
14. **Testy i zapis.** `check_merged` przelicza okna i zwroty niezależnie, sprawdza sumy i brak wycieku z przyszłości; wszystko trafia do `clean_out/merged/`.

`eff_day` (efektywny dzień handlowy) to data w Nowym Jorku, a dla zdarzeń od 16:00 NY następny dzień, bo dopiero wtedy rynek może zareagować.

Pochodzenie kolumn: events.csv

Każdy wiersz pochodzi z jednej bazy: Twitter (`trump_post`, `trump_episode`), GTA (`gta_announced`, `gta_implemented`) albo Federal Register (`fr`, `fr_effective`). Kolumna „Pole źródłowe” podaje kolumnę z pliku po czyszczeniu.

Kolumna	Twitter	GTA	Federal Register	Jak powstaje
`event_id`	`post_id`	data + `actor`	`document_number`	prefiks rodzaju (`tw_`, `ep_`, `gtaa_`, `gtai_`, `fr_`, `fre_`) + identyfikator ze źródła
`kind`	—	—	—	nadawany przy budowie zdarzeń

Kolumna	Twitter	GTA	Federal Register	Jak powstaje
`t`	`time_utc` (data publikacji posta)	`date_announced` lub `date_implemented`	`event_date` lub `effective_on`	dla dat bez godziny: północ UTC
`precision`	—	—	—	`exact` dla Twittera, `day` dla GTA i FR
`date_source`	—	nazwa pola daty	`signing_date`, `publication_date` lub `effective_on`	które pole dało `t`
`eff_day`	z `t`	z `t`	z `t`	data NY, od 16:00 NY następny dzień; dla GTA i FR sama data
`thread`, `threads`	słownik na tekście posta (`thread`)	pole `affected` (kraje dotknięte) + `actor`	słownik na `title` i `abstract`	słowa kluczowe, nie analiza znaczenia; ⩾ 3 regiony = wielostronne
`weight`	`favs` (w epizodzie suma)	suma `n_products` w dniu	—	—
`n_posts`	liczba postów w epizodzie (post = 1)	liczba interwencji w dniu	—	zliczenie
`favs`, `rts`	`favs`, `rts` (polubienia, retweety z archiwum)	—	—	w epizodzie suma
`session`, `ny_hour`	z `t`	—	—	sesja giełdy USA i godzina w Nowym Jorku

Kolumna	Twitter	GTA	Federal Register	Jak powstaje
`title`	`text` (pierwsze 140 znaków; w epizodzie posty sklejone)	`actor` + `title` (tytuł interwencji)	`title`	tylko do podglądu
`ref_id`	`post_id` (pierwszego posta)	`actor` (USA lub CHN, kraj wdrażający)	`document_number`	identyfikator do odszukania w bazie

Pochodzenie kolumn: media.csv

Kolumny media.csv to liczby z trzech baz (FNSPID, Twitter, GDELT) policzone w oknach wokół momentu `t` lub dnia `eff_day` każdego zdarzenia z `events.csv`.

Kolumna	Baza	Pole źródłowe (plik po czyszczeniu)	Jak powstaje
`event_id`	(events.csv)	—	klucz zdarzenia
`fn_n_post_h`, `fn_n_pre_h`	FNSPID	`t_utc` (dzień), `is_topic`, `is_first_in_story`	liczba niezależnych historii o cłach w dniach [d, d+n−1] (po) i [d−n, d−1] (przed); d = `eff_day` zdarzenia
`fn_all_n_post_h`, `fn_all_n_pre_h`	FNSPID	`t_utc`	wszystkie wiersze, także ta sama historia przypisana kolejnym tickerom
`fn_sector_n_post_h`, `fn_sector_n_pre_h`	FNSPID	`is_sector_note`	notki zbiorcze („Shares of several…")
`fn_th_<wątek>_n_post_h`, `..._pre_h`	FNSPID	`thread`, `is_first_in_story`	historie w danym wątku (USA_Chiny, Meksyk_Kanada, UE, Japonia_Korea_Indie, inne)
`fn_cover_post_h`, `fn_cover_pre_h`	FNSPID	zakres dat w pliku	1 = okno mieści się w całości w danych; 0 = wartości obok są puste

Kolumna	Baza	Pole źródłowe (plik po czyszczeniu)	Jak powstaje
`tw_n_post_h`, `tw_n_pre_h`	Twitter	`time_utc`, `relevant`, `is_retweet`	liczba kolejnych / wcześniejszych postów o cłach (bez RT) w (t, t+h] i [t−h, t); sam post w chwili `t` się nie liczy
`gkg_files_post_h`, `gkg_files_pre_h`	GDELT (lista pobranych paczek)	znacznik czasu w nazwie pliku `RRRRMMDDGGMMSS.gkg.csv.zip`	liczba paczek 15-min w oknie
`gkg_rate_post_h`, `gkg_rate_pre_h`	GDELT GKG	`time_utc` (pole `DATE`) artykułów w `gkg_clean.csv`	artykuły o cłach w oknie ÷ liczba paczek w oknie; brak paczek = puste
`gkg_rate_delta_h`	GDELT GKG	—	stawka po minus stawka przed (gdy oba okna mają paczki)

Horyzonty `h`: dla FNSPID 1d, 3d, 7d (tylko dni); dla tweetów i GKG 1h, 3h, 1d, 3d, 7d. Kolumny `tw_*` i `gkg_*` są wypełnione tylko dla zdarzeń z dokładnym czasem (tweety).

1. events.csv: lista zdarzeń

Jeden wiersz to jedno zdarzenie, czyli moment `t`, od którego mierzymy reakcję mediów i rynku. W Waszym przebiegu jest to 978 zdarzeń w sześciu rodzajach. Plik nie zawiera żadnej analizy treści: tylko czas, liczności i wątek ze słownika słów kluczowych.

Rodzaj (`kind`)	Liczba	Czym jest	Precyzja czasu	Prefiks `event_id`
`trump_post`	475	każdy oryginalny post o cłach (bez RT)	co do sekundy (`exact`)	`tw_<id posta>`
`trump_episode`	298	seria postów; nowy epizod po >= 6 h przerwy, `t` = pierwszy post	co do sekundy (`exact`)	`ep_<id pierwszego posta>`
`gta_announced`	75	dzień x kraj wdrażający (USA, CHN): ogłoszenie interwencji GTA	dzień (`day`)	`gtaa_RRRRMMDD_KRAJ`

Rodzaj (`kind`)	Liczba	Czym jest	Precyzja czasu	Prefiks `event_id`
`gta_implemented`	68	dzień x kraj: wejście interwencji w życie	dzień (`day`)	`gtai_RRRRMMDD_KRAJ`
`fr`	56	dokument Federal Register (data podpisu, a gdy brak, publikacji)	dzień (`day`)	`fr_<numer dokumentu>`
`fr_effective`	6	ten sam dokument: data wejścia w życie	dzień (`day`)	`fre_<numer dokumentu>`

Kolumny:

- `event_id` : unikalny identyfikator, klucz do wszystkich plików poziomu zdarzenia.
- `t` : moment zdarzenia w UTC. Dla zdarzeń dziennych to północ UTC danego dnia.
- `precision` : `exact` albo `day` . Zdarzenia dzienne mają puste horyzonty krótsze niż 1 dzień, bo nie wiadomo, o której godzinie doszło do ogłoszenia.
- `date_source` : skąd pochodzi data (`exact` , `date_announced` , `date_implemented` , `signing_date` , `publication_date` , `effective_on`).
- `eff_day` : efektywny dzień handlowy, czyli data w Nowym Jorku, a od 16:00 NY następny dzień. To klucz do paneli dziennych (`daily` , `trading`).
- `thread` , `threads` : wątek ze słownika (USA-Chiny, Meksyk/Kanada, UE, Japonia/Korea/Indie, Stal/aluminium, wielostronne, inne). `threads` zawiera wszystkie trafienia, `thread` jeden główny.
- `weight` : waga zdarzenia. Dla tweetów to liczba polubień, dla GTA liczba produktów, dla FR brak.
- `n_posts` : liczba postów w epizodzie (dla posta 1, dla GTA liczba interwencji tego dnia).
- `favs` , `rts` : polubienia i retweety (tylko Trump).
- `session` , `ny_hour` : sesja giełdy USA w chwili `t` (`przed_otwarciem` , `sesja` , `po_sesji` , `noc` , `weekend`) i godzina NY.
- `title` : pierwsze 140 znaków tekstu lub tytułu, tylko do podglądu.
- `ref_id` : identyfikator w źródle (ID posta, kraj, numer dokumentu).

`session` i `ny_hour` — szczegóły. Obie kolumny są wyliczone z `t` w czasie Nowego Jorku i wypełnione tylko dla tweetów (`trump_post` , `trump_episode`); dla GTA i FR są puste, bo nie znamy godziny decyzji. `ny_hour` to pełna godzina NY, liczba 0–23.

session	Czas w Nowym Jorku	Co to znaczy
noc	pon.–pt. 0:00–4:00	noc, w USA nic się nie dzieje
przed_otwarciem	pon.–pt. 4:00–9:30	przed otwarciem giełdy w Nowym Jorku
sesja	pon.–pt. 9:30–16:00	giełda w Nowym Jorku otwarta
po_sesji	pon.–pt. 16:00–24:00	po zamknięciu giełdy
weekend	sobota i niedziela, cały dzień	giełda zamknięta

Dwa zastrzeżenia: `session` to nie to samo co `open_at_t` w `market_long.csv` — `session` mówi o godzinach giełdy kasowej w Nowym Jorku, a `open_at_t` o tym, czy w chwili `t` był notowany konkretny instrument (kontrakty na S&P 500 i Nasdaq notowane są prawie całą dobę, TLT tylko w sesji, Hang Seng w godzinach azjatyckich). Pora dnia jest już kontrolowana w placebo (momenty kontrolne losowane z tego samego dnia tygodnia i tej samej godziny NY), więc nadwyżka `excess_abs` nie wynika z samego faktu, że rynek zwykle rusza się mocniej przy otwarciu sesji.

Rola w modelu: źródło szoku `t`. Każda analiza zdarzeniowa zaczyna się od wyboru rodzaju zdarzeń z tego pliku.

2. media.csv: media i kolejne tweety wokół zdarzenia

Jeden wiersz na zdarzenie (klucz `event_id`, 978 wierszy), a kolumny to liczby artykułów lub tweetów w oknie PO zdarzeniu i w oknie PRZED nim. Każde źródło ma inną rozdzielczość czasu, więc każde ma inne okna.

Grupa	Kolumny (h = horyzont)	Okno PO	Okno PRZED	Dla jakich zdarzeń
FNSPID	`fn_<miara>_post_h`, `fn_<miara>_pre_h`, h = 1d, 3d, 7d	dni [d, d+n−1], z dniem zdarzenia	dni [d−n, d−1]	wszystkich (d = `eff_day`)
pokrycie FNSPID	`fn_cover_post_h`, `fn_cover_pre_h`	1 = okno mieści się w danych FNSPID	jak obok	wszystkich

Grupa	Kolumny (h = horyzont)	Okno PO	Okno PRZED	Dla jakich zdarzeń
kolejne tweety	`tw_n_post_h`, `tw_n_pre_h`, h = 1h, 3h, 1d, 3d, 7d	(t, t+h]	[t−h, t)	tylko `precision = exact`
GKG: paczki	`gkg_files_post_h`, `gkg_files_pre_h`	liczba pobranych paczek 15-min w oknie	jak obok	tylko `exact`
GKG: stawka	`gkg_rate_post_h`, `gkg_rate_pre_h`, `gkg_rate_delta_h`	artykuły o cłach na paczkę	jak obok; delta = po minus przed	tylko `exact`

Miary FNSPID (`<miara>`): `fn_n` to niezależne historie o cłach (pierwsza wiadomość historii), `fn_all_n` wszystkie wiersze, `fn_sector_n` notki zbiorcze, a `fn_th_<wątek>_n` historie w danym wątku (u Was: USA_Chiny, Meksyk_Kanada, UE, Japonia_Korea_Indie, inne).

Jak czytać okna:

- Element dokładnie w chwili `t` (np. sam tweet) nie jest liczony jako reakcja. Nawias `(t, t+h]` oznacza „po `t`, do `t+h` włącznie”.
- FNSPID ma tylko daty, więc okno PO zawiera dzień zdarzenia: nie wiadomo, czy artykuł z tego dnia ukazał się przed tweetem, czy po nim. Dzień zdarzenia to `eff_day`, więc tweet po 16:00 NY liczy się do dnia następnego.
- Gdy okno wychodzi poza zakres danych FNSPID, wartość jest pusta (NaN), a `fn_cover_* = 0`. Nie jest to zero artykułów.
- Przykład: dane FNSPID kończą się 2019-06-30. Zdarzenie z `eff_day = 2019-06-28` ma okno `post_7d` = dni 28–30 czerwca i 1–4 lipca — 1–4 lipca nie istnieją w danych, więc `fn_n_post_7d` jest NaN (nie zaniżoną sumą z 3 dni), a `fn_cover_post_7d = 0`.
- GKG to próbka paczek, więc liczymy stawkę na paczkę, a nie sumę artykułów. Okno bez żadnej paczki daje NaN. U Was paczki pokrywają tylko ok. 6% zdarzeń, więc kolumny GKG są prawie puste.
- Tweety o cłach w oknie po tweecie (`tw_n_post_*`) mówią, czy zdarzenie zaczyna serię, a w oknie przed (`tw_n_pre_*`), czy jest jej kontynuacją.

Rola w modelu: ogniwo Trump → media na poziomie zdarzenia. Porównanie `_post_` z `_pre_` mówi, czy po zdarzeniu media piszą więcej niż przed nim.

3. market_long.csv: reakcja rynku z kontrolą placebo

Jeden wiersz to zdarzenie × instrument × horyzont. U Was to 34 230 wierszy (978 zdarzeń × 5 instrumentów × 7 horyzontów). To główny plik do analizy zdarzeniowej, bo każdy zwrot ma tu własną kontrolę.

Kolumna	Znaczenie	Jednostka
`event_id`	zdarzenie (klucz do `events.csv`)	
`instrument`	S&P 500, Nasdaq, Hang Seng, EURUSD, TLT	
`horizon`	1m, 5m, 1h, 3h, 1d, 3d, 7d	
`ret`	log P(t+h) / P(t), gdzie P(t) to cena otwarcia ostatniej świecy 5-min rozpoczętej przed `t` lub w `t`	log-zwrot (×10⁴ = pb)
`abs_ret`	|ret|, wielkość ruchu bez znaku	log-zwrot
`pre_ret`	log P(t) / P(t−h): ruch PRZED zdarzeniem, kontrola wycieku informacji i trendu	log-zwrot
`ctl_ret`, `ctl_abs`	średni zwrot i średni |zwrot| z kontroli placebo	log-zwrot
`excess_ret`	`ret − ctl_ret`: nadwyżka kierunkowa	log-zwrot
`excess_abs`	`abs_ret − ctl_abs`: nadwyżka wielkości ruchu (użyta na slajdzie 2)	log-zwrot
`open_at_t`	czy w chwili `t` rynek był notowany (świeża cena)	prawda/fałsz
`ctl_n`	ile chwil kontrolnych wylosowano dla zdarzenia (cel: 20)	liczba
`ctl_unique_share`	udział unikalnych chwil kontrolnych dla rodzaju zdarzeń i instrumentu	0–1

Kontrola placebo: dla każdego zdarzenia losujemy do 20 chwil z tego samego dnia tygodnia i tej samej godziny w Nowym Jorku, z dala od zdarzeń tego samego rodzaju (±2 h dla tweetów, ±1 dzień dla zdarzeń dziennych). Usuwa to efekt pory dnia, np. większy ruch przy otwarciu sesji.

Puste wartości są celowe:

- t+1m jest zawsze pusty, bo świece mają 5 minut.
- Horyzonty krótsze niż 1 dzień są puste dla zdarzeń dziennych (GTA, FR) i dla tweetów przy zamkniętym rynku (noc, weekend).

- TLT i Hang Seng są notowane tylko w swoich sesjach, więc mają mniej wartości (pokrycie TLT ok. 20%, Hang Seng ok. 52% epizodów).

Rola w modelu: ogniwo Trump → rynek i decyzje → rynek. Średnie `excess_abs` po zdarzeniach z przedziałem ufności dają funkcja `excess_table` i slajd 2.

4. event_table.csv: wszystko o zdarzeniu w jednym wierszu

To `events.csv` z doklejonymi kolumnami z `media.csv` i z `market_long.csv` rozpisanym szeroko: 978 wierszy, u Was 245 kolumn. Plik powstaje z łączenia po `event_id` w relacji 1:1, więc żadne zdarzenie nie jest zdublowane ani zgubione (sprawdza to test „tabela zdarzeń 1:1 po scaleniu").

Blok kolumn	Skąd	Przykład
zdarzenie (16 kolumn)	`events.csv`	`event_id`, `kind`, `t`, `eff_day`, `thread`, `session`
media	`media.csv`	`fn_n_post_1d`, `tw_n_pre_1h`, `gkg_rate_delta_3h`
rynek: 5 instrumentów × 4 miary × 7 horyzontów = 140 kolumn	`market_long.csv`	`S_P_500_ret_1h`, `S_P_500_excess_abs_1h`, `Hang_Seng_pre_ret_1d`

Kolumny rynkowe mają postać `<INSTRUMENT>_<miara>_<horyzont>`, gdzie instrument to `S_P_500`, `Nasdaq`, `Hang_Seng`, `EURUSD` lub `TLT`, a miara to `ret`, `excess_ret`, `excess_abs` lub `pre_ret`. Kontroli (`ctl_*`) tu nie ma, bo są w `market_long.csv`.

Rola w modelu: tabela do regresji na poziomie zdarzenia, gdy jedna zmienna ma wyjaśniać drugą. Na przykład: czy większy ruch rynku po tweecie (`S_P_500_excess_abs_1d`) idzie w parze z większą liczbą artykułów po tweecie (`fn_n_post_1d`), przy kontroli wątku, sesji i liczby polubień.

5. daily.csv i trading.csv: panele dzienne

Oba pliki mają te same kolumny i jeden wiersz na dzień. Różnią się kalendarzem: `daily.csv` ma wszystkie 730 dni 2018–2019, a `trading.csv` tylko 521 dni handlowych. Kluczem jest kolumna `day`, czyli efektywny dzień handlowy: data w Nowym Jorku, a od 16:00 NY dzień następny. To ten sam klucz co `eff_day` w `events.csv`, więc tweet po zamknięciu sesji trafia do dnia, w którym rynek może na niego zareagować.

Grupa	Kolumny	Znaczenie	U Was (dni handlowe)
Trump	`tw_n`, `tw_topic_n`, `tw_share`	wszystkie oryginalne posty, posty o cłach, udział o cłach	o cłach: średnio 0,9 dziennie, maks. 23
FNSPID	`fn_n`, `fn_all_n`, `fn_sector_n`, `fn_th_<wątek>_n`, `fn_sector_share`	historie o cłach, wszystkie wiersze, notki zbiorcze, wątki	`fn_n`: średnio 1,6 dziennie, maks. 38
decyzje	`gta_ann_n`, `gta_ann_products_n`, `gta_impl_n`, `gta_impl_products_n`, `fr_n`, `fr_eff_n`	liczba ogłoszeń i wdrożeń GTA (z liczbą produktów), dokumenty FR	rzadkie: średnio 0,1 dziennie
GKG	`gkg_files_n`, `gkg_topic_n`, `gkg_rate`	pobrane paczki 15-min, artykuły o cłach, artykuły na paczkę	stawka tylko w 25 dniach
rynek	`<INSTRUMENT>_ret`, `<INSTRUMENT>_absret`, `<INSTRUMENT>_rv`	log-zwrot dnia, jego wartość bezwzględna, zmienność zrealizowana	S&P 500: odchylenie zwrotu 0,94% dziennie

Rynek w panelu:

- `_ret` to log(ostatnia cena dnia / ostatnia cena poprzedniego dnia), w tym samym kluczu dnia co tweety.
- `_rv` to suma kwadratów zwrotów 5-minutowych wewnątrz sesji, bez skoków przez noc i weekend.
- Dzień bez notowań instrumentu ma NaN. Hang Seng ma więcej braków niż S&P 500, bo obowiązują go święta w Hongkongu.

Czym `trading.csv` różni się od `daily.csv`:

- Weekendy i święta są doliczone do najbliższego dnia handlowego. Tweet z soboty trafia do poniedziałku, kiedy rynek może zareagować.
- Liczniki (`_n`) i log-zwroty (`_ret`, `_rv`) są sumowane, bo log-zwroty się dodają. Wartości `_absret` i udziały są liczone od nowa z sum.
- Sumy są zachowane, co sprawdzają testy (np. 475 postów o cłach w obu plikach).

NaN a zero: w licznikach zero znaczy „były dane i nie było zdarzeń". Wyjątek to GKG: `gkg_files_n = 0` oznacza, że tego dnia nie mamy żadnej paczki, czyli brak danych. W takie dni `gkg_rate` jest NaN.

Brakuje VIX. Plik `data/vix_daily.csv` nie jest w panelu; dołącza się go po dacie (kod w sekcji 7).

Rola w modelu: `trading.csv` to ciągły szereg do Local Projections i PCMCI+ (sekcja 7), a `daily.csv` do wykresów i profili dni wokół zdarzeń (slajd 3).

6. hourly.csv: panel godzinowy

Jeden wiersz na godzinę UTC (kolumna `hour_utc`), 17 520 godzin w 2018–2019. Nie ma tu FNSPID ani decyzji GTA i FR, bo są tylko dzienne.

Kolumny	Znaczenie
`tw_n`, `tw_topic_n`	wszystkie oryginalne posty i posty o cłach w danej godzinie
`gkg_files_n`, `gkg_topic_n`, `gkg_rate`	pobrane paczki GKG, artykuły o cłach, artykuły na paczkę (NaN, gdy brak paczki)
`<INSTRUMENT>_ret`, `<INSTRUMENT>_rv`	suma log-zwrotów 5-min w godzinie i ich kwadratów (zmienność zrealizowana); NaN, gdy brak notowań
`us_session`	1 = godzina w sesji giełdy USA (9:30–16:00 NY, pon.–pt.)
`weekend`	1 = sobota lub niedziela w NY

Rola w modelu: test kolejności w skali godzin, którego nie da się zrobić na danych dziennych (slajd 3). Dziś działa dla Trump → rynek (np. Local Projections godzinowe: |zwrot| w godzinach t+1…t+6 na tweety w godzinie t, z kontrolą `us_session`). Dla mediów wymaga GKG pobranego gęsto wokół zdarzeń: dziś `gkg_files_n` jest zerem w większości godzin.

7. Jak połączyć pliki w modelu

Łańcuch ma trzy ogniwa: Trump → media → rynek oraz bezpośrednio Trump → rynek. Każde ogniwo bada się na innym pliku, w zależności od tego, czy potrzebna jest precyzja zdarzenia (minuty), czy ciągły szereg (dni).

Ogniwo	Plik	Metoda	Zmienne
Trump → rynek (minuty, godziny)	`market_long.csv`	analiza zdarzeniowa z placebo	`excess_abs` dla `kind = trump_episode`
decyzje GTA/FR → rynek	`market_long.csv`	analiza zdarzeniowa, horyzonty >= 1d	`excess_abs` dla `gta_*`, `fr`
Trump → media	`media.csv` lub `event_table.csv`	porównanie okien po i przed	`fn_n_post_h` vs `fn_n_pre_h`
media → rynek przy tweecie	`event_table.csv`	regresja na zdarzeniach	`S_P_500_excess_abs_1d` na `fn_n_post_1d`
cały łańcuch w czasie	`trading.csv`	Local Projections, PCMCI+	`tw_topic_n`, `fn_n`, `gta_ann_n`, `fr_n`, `S_P_500_absret`, VIX
kolejność w godzinach	`hourly.csv`	Local Projections godzinowe	`tw_topic_n`, `<INSTRUMENT>_rv`, `gkg_rate`

Klucze łączenia

- poziom zdarzenia: `event_id` (`events`, `media`, `market_long`, `event_table`);
- zdarzenie → dzień: `events.eff_day` = `daily.day` (w `trading` dzień weekendowy przechodzi na najbliższy dzień handlowy);
- panel godzinowy: `hour_utc` = `t` zaokrąglone w dół do pełnej godziny.

```
import numpy as np, pandas as pd
M = "clean_out/merged/"
E = pd.read_csv(M + "events.csv", parse_dates=["t", "eff_day"])
L = pd.read_csv(M + "market_long.csv")
# zdarzenie x instrument x horyzont + opis zdarzenia (m:1 = każdy wiersz L ma
dokładnie jedno zdarzenie)
X = L.merge(E[["event_id", "kind", "eff_day", "thread", "session"]],
on="event_id", validate="m:1")
# + kontekst dnia z panelu (ile było artykułów i ruchu tego dnia)
D = pd.read_csv(M + "daily.csv", index_col="day", parse_dates=["day"])
X = X.merge(D, left_on="eff_day", right_index=True, how="left")
```

Ogniwo media → rynek na zdarzeniach

```
import statsmodels.formula.api as smf
T = pd.read_csv(M + "event_table.csv", parse_dates=["t", "eff_day"])
d = T[T.kind == "trump_episode"].dropna(subset=["S_P_500_excess_abs_1d",
"fn_n_post_1d"])
m = smf.ols("S_P_500_excess_abs_1d ~ fn_n_post_1d + fn_n_pre_1d +
np.log1p(favs) + C(session)", d).fit(cov_type="HC1")
print(m.summary())
```

Local Projections (Jordà) na dniach handlowych

Dla każdego horyzontu h osobna regresja: zmienna wynikowa w dniu t+h na szoku w dniu t, z opóźnieniami jako kontrolą. Współczynnik `beta` w kolejnych h to funkcja reakcji.

```
P = pd.read_csv(M + "trading.csv", index_col="day", parse_dates=["day"])
vix = pd.read_csv("data/vix_daily.csv", parse_dates=
["date"]).set_index("date")["vix"]
P["vix"] = vix.reindex(P.index)   # VIX dokładany po dacie
P["d_vix"] = P["vix"].diff()

def lp(P, y, x, H=5, controls=("fn_n",), lags=2):
    rows = []
    for h in range(H + 1):
        d = pd.DataFrame({"y_h": P[y].shift(-h), "x": P[x]})
        for k in range(1, lags + 1):
            d[f"y_l{k}"], d[f"x_l{k}"] = P[y].shift(k), P[x].shift(k)
            for c in controls:
                d[f"{c}_l{k}"] = P[c].shift(k)
        d = d.dropna()
        f = "y_h ~ x + " + " + ".join(c for c in d.columns if c not in
("y_h", "x"))
        r = smf.ols(f, d).fit(cov_type="HAC", cov_kwds={"maxlags": h + 1})
        lo, hi = r.conf_int().loc["x"]
        rows.append({"h": h, "beta": r.params["x"], "lo": lo, "hi": hi, "n":
int(r.nobs)})
    return pd.DataFrame(rows).set_index("h")

lp(P, "S_P_500_absret", "tw_topic_n")                          # Trump ->
rynek
lp(P, "fn_n", "tw_topic_n", controls=("S_P_500_absret",))    # Trump -> media
lp(P, "S_P_500_absret", "fn_n", controls=("tw_topic_n",))    # media ->
rynek, przy kontroli tweetów
```

PCMCI+ na dniach handlowych

PCMCI+ szuka skierowanych zależności z opóźnieniem (np. tweety w dniu t−1 → artykuły w dniu t) i zależności tego samego dnia. Wymaga ciągłego szeregu bez braków, dlatego używamy `trading.csv`.

```
from tigramite import data_processing as pp
from tigramite.pcmci import PCMCI
from tigramite.independence_tests.parcorr import ParCorr

cols = ["tw_topic_n", "fn_n", "gta_ann_n", "fr_n", "S_P_500_absret", "d_vix"]
Z = P[cols].copy()
for c in ("tw_topic_n", "fn_n", "gta_ann_n", "fr_n"):
    Z[c] = np.log1p(Z[c])          # liczności: log(1+x) łagodzi skoki
Z = Z.fillna(Z.mean())             # nieliczne braki (święta); alternatywa:
missing_flag w tigramite
df = pp.DataFrame(Z.to_numpy(float), var_names=cols)
pcmci = PCMCI(dataframe=df, cond_ind_test=ParCorr(significance="analytic"),
verbosity=0)
res = pcmci.run_pcmciplus(tau_min=0, tau_max=3, pc_alpha=0.05)
pcmci.print_significant_links(p_matrix=res["p_matrix"],
val_matrix=res["val_matrix"], alpha_level=0.05)
```

Zależności z opóźnieniem 0 (ten sam dzień) PCMCI+ często zostawia bez kierunku. Na danych dziennych nie wiadomo, co było pierwsze: tweet, artykuł czy ruch rynku. O kierunku mówią opóźnienia >= 1 albo dane godzinowe.

Kod sprawdziłem na danych testowych. Wymaga bibliotek `statsmodels` i `tigramite` (`pip install statsmodels tigramite`).

8. Pułapki przy używaniu plików

1. **Posty i epizody naraz.** Pierwszy post każdego epizodu występuje dwa razy: jako `trump_post` i jako `trump_episode`, z tym samym `t`. W jednej analizie wybierz jeden rodzaj. Epizody są lepsze do testów, bo ich okna się nie nakładają.
2. **NaN to nie zero.** Puste wartości oznaczają brak danych: rynek zamknięty, okno poza FNSPID, brak paczki GKG. Nie zastępuj ich zerem, bo zaniżysz średnie. Zero w liczniku dziennym oznacza „były dane, nie było zdarzeń” (z wyjątkiem GKG, sekcja 5).
3. **Klucz dnia.** Panele używają `eff_day` (od 16:00 NY następny dzień), a nie daty UTC. Łącz po `eff_day`, nie po dacie z `t`, bo inaczej tweet z wieczora trafi do niewłaściwego dnia.
4. **Zdarzenia dzienne.** GTA i FR mają tylko datę. Nie mają horyzontów krótszych niż dzień i nie da się ich porównać z tweetami w minutach.

5. **FNSPID w dniu zdarzenia.** Artykuły z tego samego dnia są w oknie PO (`fn_*_post_1d`), choć mogły ukazać się przed tweetem. Kierunku media → rynek nie rozstrzyga się na tym oknie.
6. **Wielokrotne testowanie.** Przy 5 instrumentach × 6 horyzontach × 4 rodzajach zdarzeń kilka wyników wyjdzie istotnych przypadkiem. Przed wnioskami popraw p-wartości, np. `statsmodels.stats.multitest.multipletests(p, method="fdr_bh")`, albo załóż z góry, które testy są główne (np. S&P 500 przy 5m i 1h).
7. **Słownik cłów.** „Tweet o cłach" to trafienie słownika, a nie odczytany sens. Część postów dotyczy innych tematów (np. sankcji wobec Korei Północnej). Sprawdź próbkę w sekcji 3b notebooka.
8. **Plik nadpisuje się przy każdym przebiegu.** `build_merged` zapisuje `clean_out/merged/` od nowa. Wyniki do pracy zapisuj osobno, z datą przebiegu.